Procesamiento digital de imágenes satelitales y datos geoespaciales

Docente:Dr. Santiago Ariel Seppi (CONAE-UNC)

Gulich UNC CONAE

Contenidos

- **Clase 01:** Imágenes en el entorno de programación. Manejo básico de archivos, librerías y estructuras básicas en Python.
- **Clase 02**: Características de las imágenes satelitales. Lectura y tratamiento de imágenes satelitales y datos geoespaciales con Python.
- **Clase 03**: Aprendizaje supervisado. El espacio de atributos. Firmas espectrales. Generación y lectura de muestras para entrenar. Clasificadores supervisados con librería Scikit-Learn. Cómputo de métricas de error. Aplicaciones sobre imágenes satelitales

Aprendizaje supervisado

Dada una serie de valores X junto a una variable de respuesta Y:

$(X_1, Y_1), (X_2, Y_2), \ldots, (X_n, Y_n)$ ¿Quiénes o qué son nuestros X?

Se busca aprender una función $f(x)$ que permita predecir a Y a partir de X

Si Y se encuentra en el dominio de los números reales (es una variable continua) hablamos de **regresión**

Si Y es una variable categórica hablamos de un problema de **clasificación.**

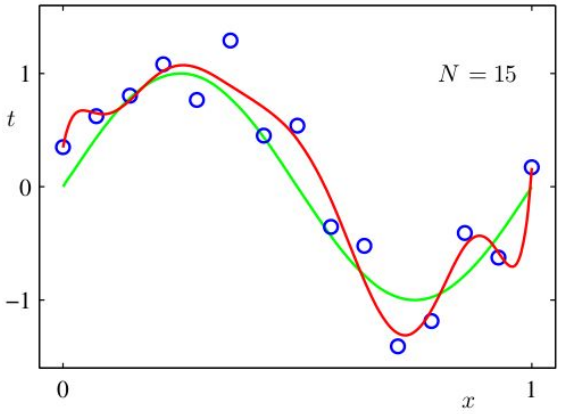
® GULICH | Todos los derechos reservados

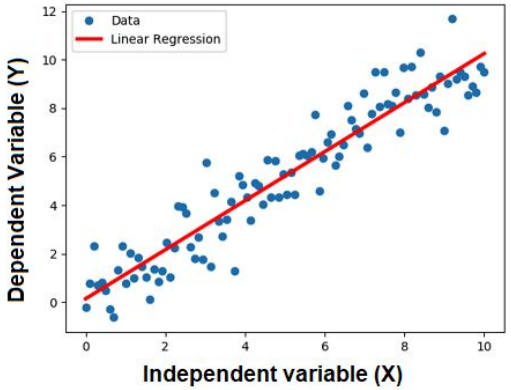
Aprendizaje supervisado: Regresión

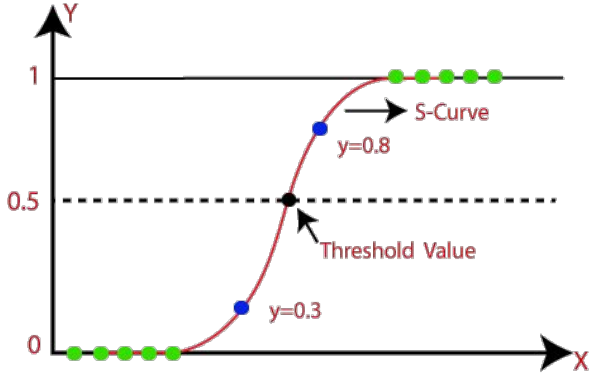
Dada una serie de valores X junto a una variable de respuesta Y:

$(X_1, Y_1), (X_2, Y_2), \ldots, (X_n, Y_n)$

Se busca aprender una función $f(x)$ que permita predecir a Y a partir de X







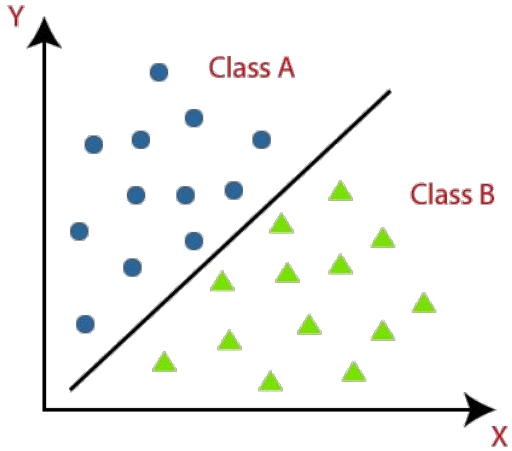
® GULICH | Todos los derechos reservados

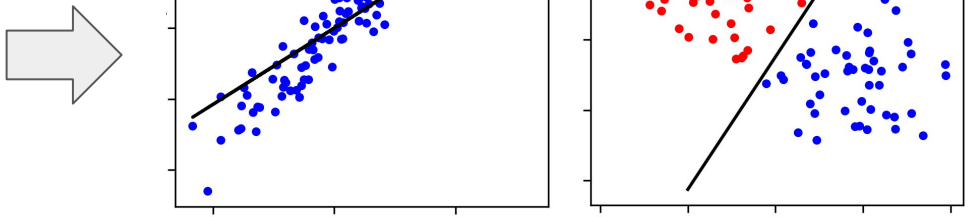
Aprendizaje supervisado: Clasificación

Dada una serie de valores X junto a una variable de respuesta Y:

$(X_1, Y_1), (X_2, Y_2), \ldots, (X_n, Y_n)$

Se busca aprender una función $f(x)$ que permita predecir a Y a partir de X

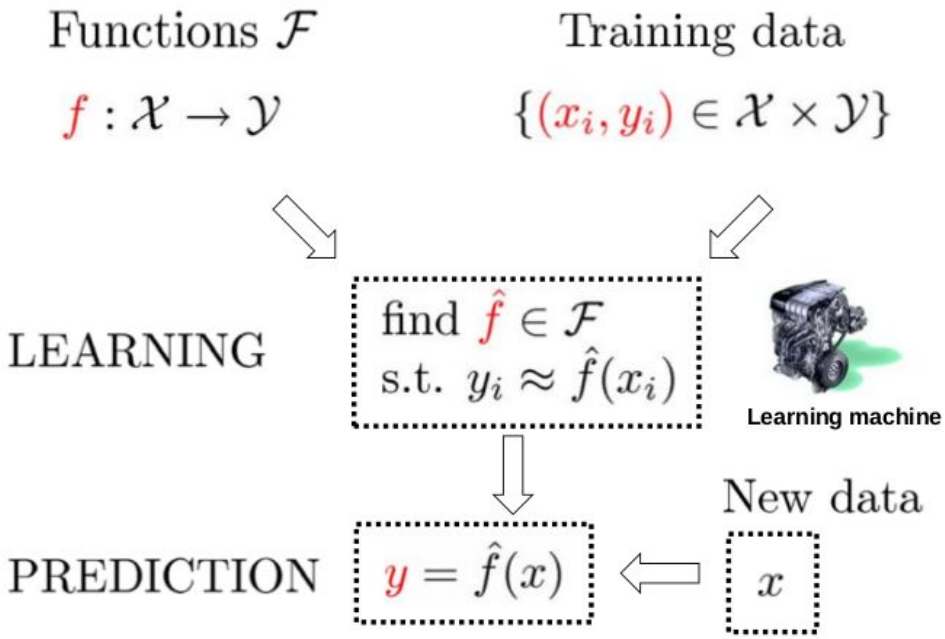




® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación

Los problemas que encaramos en nuestras clases se encuadran dentro de una **clasificación**. A partir de un conjunto de píxeles (datos) etiquetados (muestras), debemos enseñarle a un clasificador como asignar correctamente el número de clase al resto de los píxeles



® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación

Métodos paramétricos	Métodos no paramétricos
Construyen la función que aproxima los datos de entrenamiento a la variable objetivo con un número fijo de parámetros, con independencia de la cantidad de datos con los que se entrene	No se asume una forma concreta en el modelo a generar, resultando más flexibles, pero a costa de requerir más datos para su entrenamiento
Ejemplos: Regresión lineal, perceptrón multicapa , Máxima Verosimilitud	Ejemplos: KNN, SVM, Árboles de decisión

¡¡NOS CENTRAMOS EN ESTOS!!

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

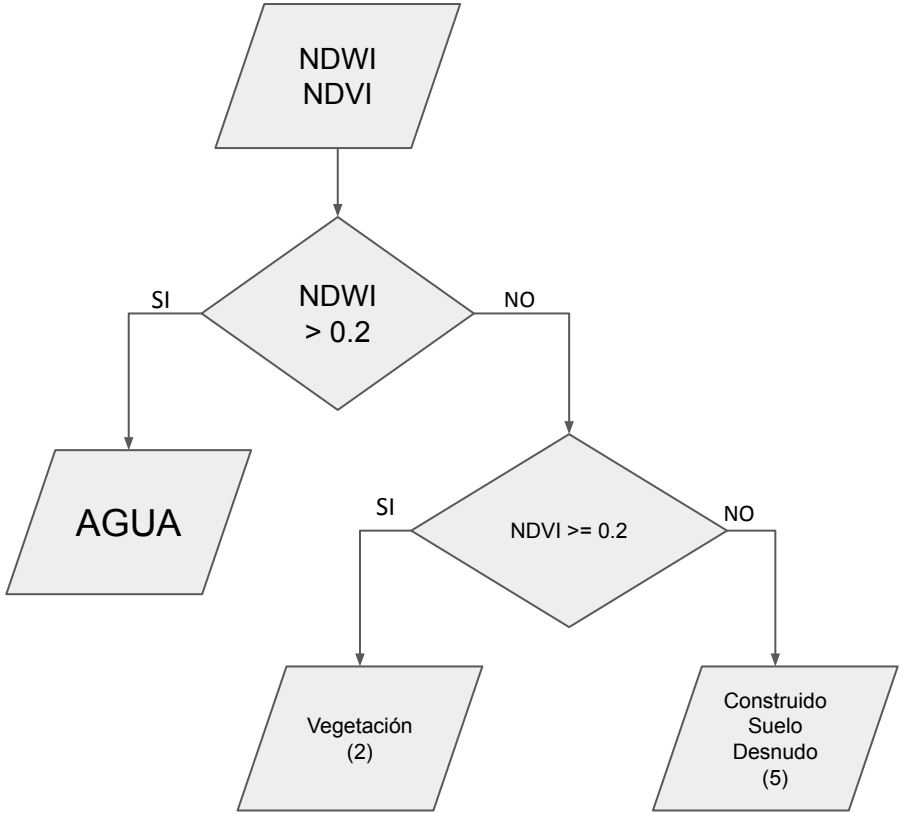
- Es un método de aprendizaje supervisado que, en base a determinadas *reglas*, decide asignar una observación a una determinada clase.
- Las variables se usan para crear *preguntas* del tipo SI/NO en base a las cuales se irá dividiendo a los datos en distintos subconjuntos que son mutuamente excluyentes entre sí.
- Cada vez que añadimos una pregunta, estamos agregándole un *nodo* al árbol. El nodo o pregunta inicial se denomina **nodo raíz**.
- Cuando ya no se pueden dividir más los datos, los nodos resultantes se denominan nodos hojas o *leaf nodes* en inglés.

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ejemplo “manual”: Para evaluar si el píxel es o no agua, aplicamos un umbral sobre el NDWI. Podríamos considerar que los píxeles no clasificados como agua, o son **vegetación**, o corresponden a superficies **construidas / suelo desnudo**, en base a un umbral sobre el NDVI.

Pero si lo quiero hacer automáticamente ¿Cómo elijo las variables de partida, los umbrales o preguntas a hacer? ¿Cómo saber cuándo dejar de hacer preguntas?

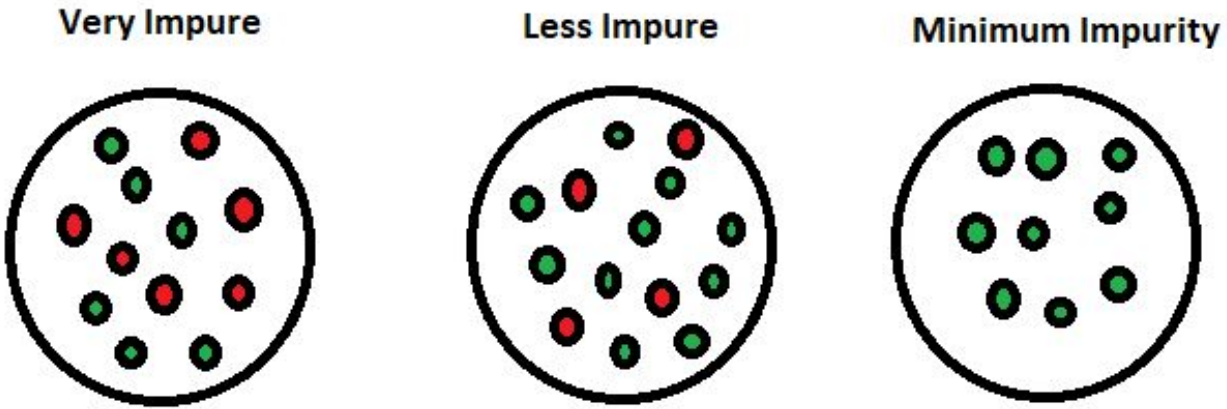


® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Pero si lo quiero hacer automáticamente ¿Cómo elijo las variables de partida, los umbrales o preguntas a hacer? ¿Cómo saber cuándo dejar de hacer preguntas?

Una manera es medir la *impureza* o el nivel de *incertidumbre* luego de tomar una decisión.



® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Medidas de incertidumbre o *desorden*

Índice de GINI (G)

$$G(\text{node}) = \sum_{k=1}^{c} p_k(1 - p_k)$$

Probability of *not* picking a data point from class *k*

Probability of picking a data point from class *k*

$$p_k = \frac{\text{number of observations with class k}}{\text{all observations in node}}$$

Entropía: H(Y)

$$\text{Entropy}(\text{node}) = -\sum_{i=1}^{c} p_k \log(p_k)$$

Probability of picking a data point from class *k*

$$p_k = \frac{\text{number of observations with class k}}{\text{all observations in node}}$$

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Dique Roggero (Buenos Aires, Arg.)



Clase	Pixeles	P_k
Agua	180000	0.45
Tierra	220000	0.55

Entropía inicial:

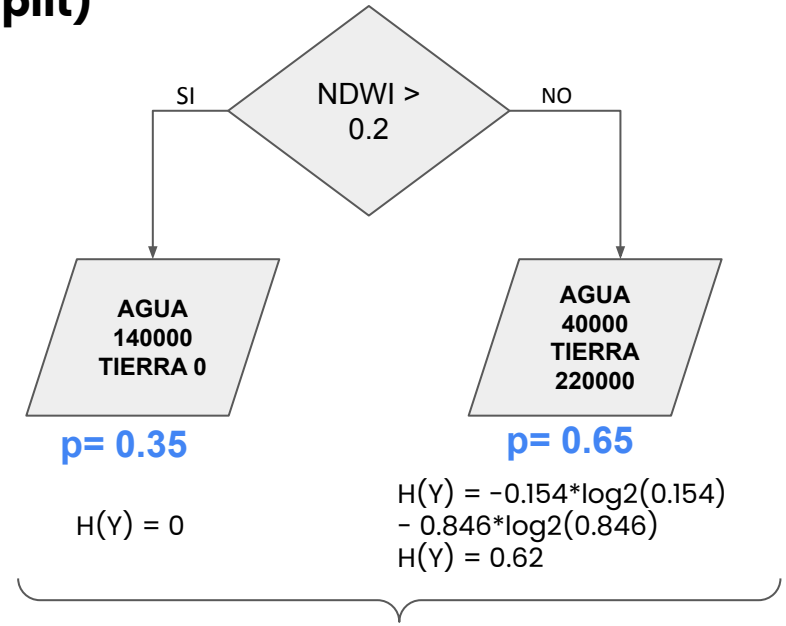
$H(Y) = -0.45*\log2(0.45) - 0.55*\log2(0.55)$
$H(Y) = 0.518 + 0.474$
$H(Y) = 0.992$

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ganancia de información (IG): ¿Cuánta información nos da una variable sobre nuestras clases? → Entropía de una división: **H(split)**



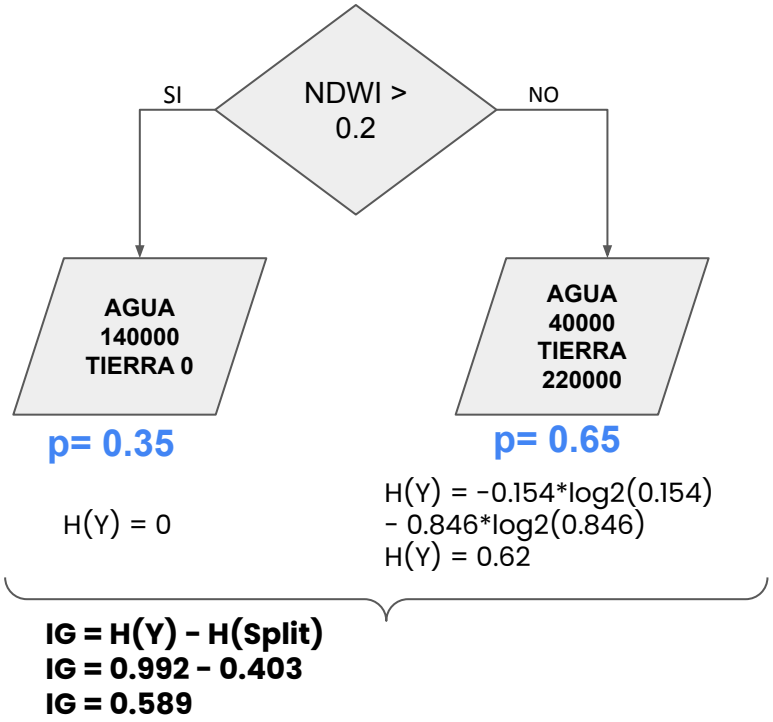


® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ganancia de información (IG): ¿Cuánta información nos da una variable sobre nuestras clases? → **H(parent) - H(split)**



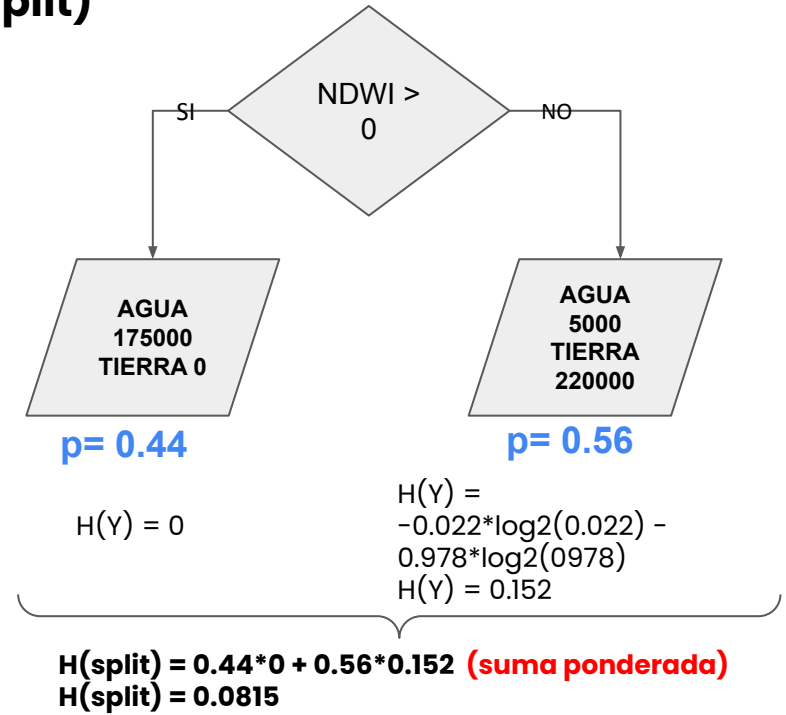


® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ganancia de información (IG): ¿Cuánta información nos da una variable sobre nuestras clases? → Entropía de una división: **H(split)**



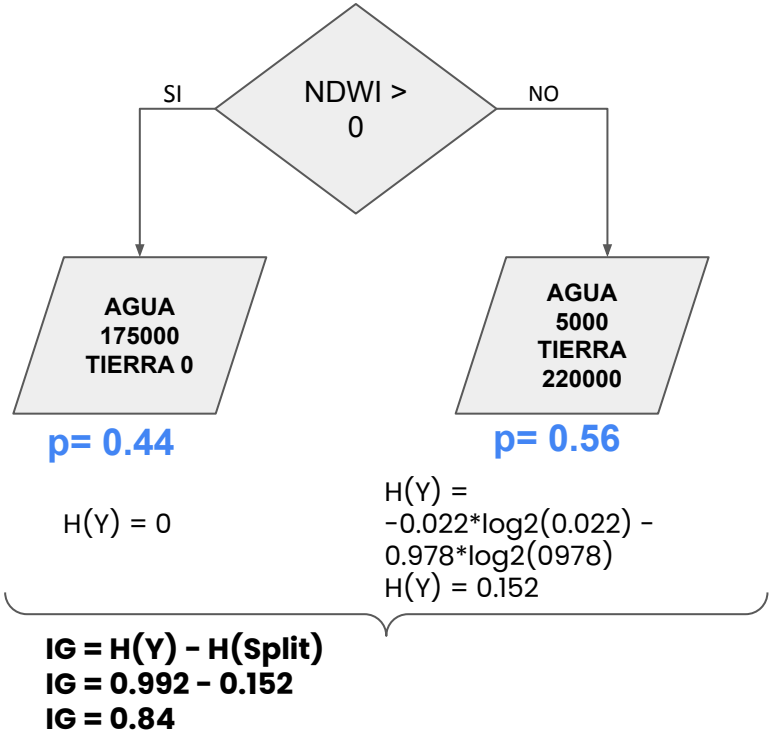


® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ganancia de información (IG): ¿Cuánta información nos da una variable sobre nuestras clases? → **H(parent) - H(split)**





® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ganancia de información (IG): ¿Cuánta información nos da una variable sobre nuestras clases? → **H(parent)** - **H(split)**

Cambiar el umbral de NDWI genera divisiones o *splits* diferentes:

- Usando un umbral de 0.2, la Ganancia de Información es 0.589
- Usando un umbral de 0, la Ganancia de información es 0.84
- **Los árboles de decisión eligen los nodos en base a los atributos que maximizan la Ganancia de Información. Toma decisiones que son *localmente* óptimas.**
- El proceso de ir calculando la Entropía (H) y la Ganancia de Información (IG) se repite iterativamente a medida que se avanza en la división.

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

¿Cuándo parar de hacer nuevas ramificaciones?

- Si optimizamos sin límite podemos llegar al árbol *perfecto* (con todos nodos puros) para nuestro conjunto de datos→ Overfitting

Principales parámetros que se pueden ajustar:

- Máxima profundidad (max_depth)
- Número mínimo de muestras para formar un nodo (min_samples_leaf)
- Número de variables a considerar para buscar la mejor división (max_features)

Otra alternativa: Podado o *pruning*

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Árboles de decisión

Ventajas:

- Fáciles de interpretar (se puede *imprimir* todo el árbol)
- No se requiere pre-procesamiento (por ejemplo: Normalización de los datos).
- Puede trabajar tanto con variables categóricas como numéricas.
- Computacionalmente eficientes

Desventajas:

- Si no se define una heurística o límite adecuado para las ramificaciones, los árboles tienden a sobre-ajustar.
- Pueden ser muy inestables con valores extremos
- No son adecuados para conjuntos de datos muy grandes → Para estos casos es preferible usar **Random Forests**

® GULICH | Todos los derechos reservados

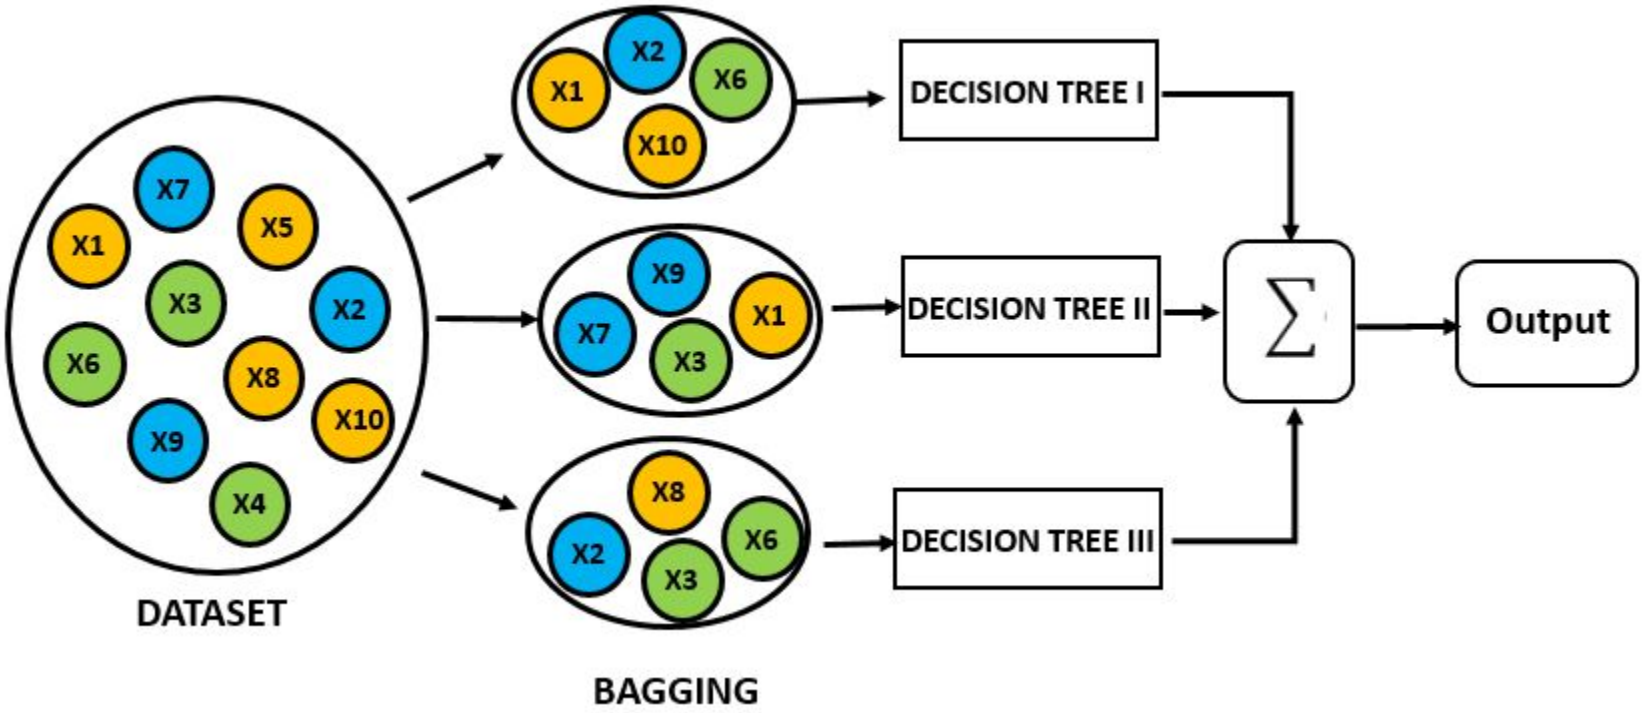
Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests

- Random Forest forma parte de la familia de algoritmos de aprendizaje conjunto (o ***Ensemble learning*** en inglés)
- El Random Forest es una versión modificada de un método de Ensemble que se conoce como ***Bagging*** → ¿Qué es el Bagging?

1. Dado un conjunto inicial ***D***, se repite ***n*** veces lo siguiente:
- Generar un subconjunto ***Di***, a partir de una selección aleatoria de elementos de **D**.
- Entrenar un modelo ***Mi***, con los datos de ***Di***
1. El modelo M elige las predicciones o resultados más “votados” (más frecuentes) de todos los **{*Mi*}**

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests



Fuente: ***Bookdown***

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests

1. Bagging generalmente se usa con árboles de decisión, para mitigar su *inestabilidad*.
2. **Problema**: Entrenar ***n*** árboles de decisión completos resulta computacionalmente ***n*** veces más caro que hacerlo con uno solo.
3. Posible solución: **Random Forests:**
   a. Al entrenar cada árbol de decisión, se lo hace solo con un subconjunto ***K*** de atributos o variables elegidos aleatoriamente.
   b. Esta cantidad de atributos es un hiperparámetro del modelo . Criterio habitual: **K = sqrt(# atributos)**

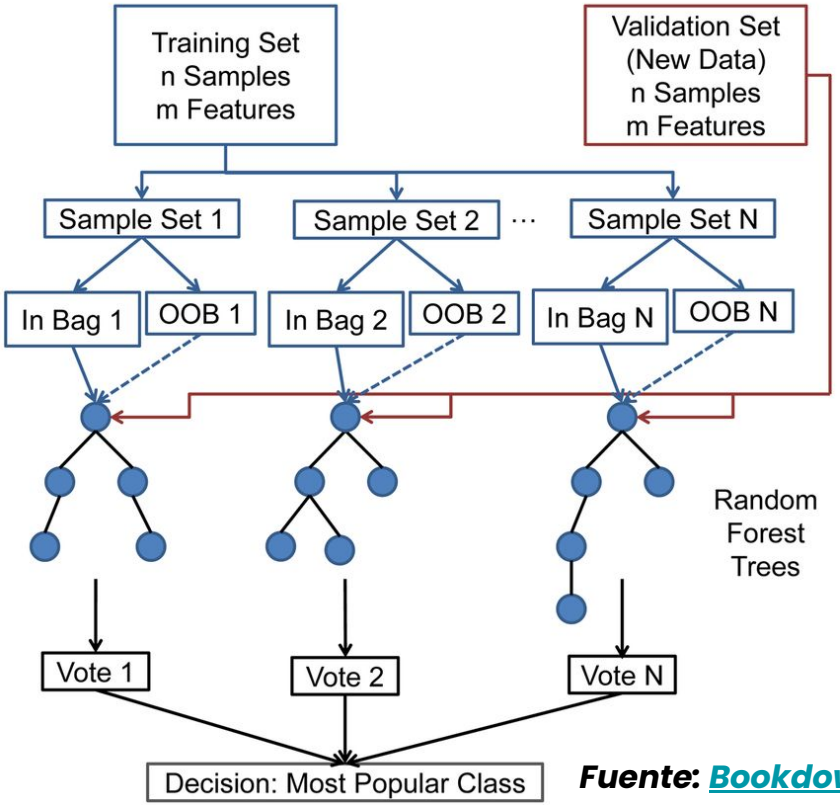
® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests

1. Dado un conjunto inicial ***D***, se repite ***n*** veces lo siguiente:
- Generar un subconjunto ***Di***, a partir de una selección aleatoria de elementos de **D**.
- Entrenar un árbol de decisión con los datos de ***Di***, utilizando un subconjunto K de atributos elegidos aleatoriamente
- Se repite hasta que el árbol esté completo (no se hace *pruning*, aunque sí se puede poner un límite en la profundidad máxima de cada árbol)
1. El modelo M elige las predicciones o resultados más "votados" (más frecuentes) de todos los **{*Mi*}**

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests



Fuente: ***Bookdown***

Principales parámetros:

- Cantidad de árboles
- Cantidad de variables o features por cada árbol
- Tamaño del subconjunto para entrenar cada árbol
- Parámetros propios de un árbol de decisión: Máxima profundidad (**max_depth**), Número mínimo de muestras para formar un nodo (**min_samples_leaf**)

® GULICH | Todos los derechos reservados

Aprendizaje supervisado: Clasificación
Métodos no paramétricos: Random Forests

Ventajas:

- Todas las que tienen los Árboles de decisión +
- Sencillos de implementar
- Mayor robustez al basarse en ***Bagging***

Desventajas:

- Comparado a Árboles de decisión, no es tan fácil interpretarlos (¡tenemos muchos árboles en lugar de uno!)
- Costo computacional mayor que un árbol de decisión solo (aunque menor que Bagging)
- No funciona bien con conjuntos demasiado pequeños

® GULICH | Todos los derechos reservados

Antes de clasificar … debemos generar muestras

Notebook 03a: Generación de muestras



MUCHAS GRACIAS

¿Preguntas?

Gulich UNC CONAE